

Департамент образования и науки города Москвы
Государственное автономное образовательное учреждение высшего
образования города Москвы «Московский городской педагогический
университет»
Институт цифрового образования
Департамент информатики, управления и технологий

Лабораторная работа 5.1.

Развертывание и настройка Hadoop. Анализ данных с использованием
экосистемы Hadoop

Выполнил студент группы АДЭУ-221

Джамалова Сабина Шахиновна

Проверил доцент

Босенко Тимур Муртазович

Москва

2025

Оглавление

Введение.....	3
Запуск проекта.....	8
Шаг 1. Клонирование и подготовка	8
Шаг 2. Запуск Docker контейнера	8
Шаг 3. Подключение к контейнеру	9
Шаг 4. Проверка компонентов Hadoop	9
Работа с HDFS	10
Шаг 1. Создание директорий	10
Шаг 2. Загрузка данных.....	10
Шаг 3. Просмотр данных в HDFS	10
Шаг 4. Веб-интерфейсы	10
Анализ данных	12
Загрузка данных:	12
Очистка данных:	13
MapReduce анализ на очищенных данных	16
Расширенный анализ факторов риска.....	16
Выводы:	22

Введение

Цель работы: получить практические навыки развертывания одноузлового кластера Hadoop, освоить базовые операции с распределенной файловой системой HDFS, выполнить загрузку и простейшую обработку данных, а также научиться выгружать результаты для последующего анализа и визуализации во внешней среде.

Вариант задания: 6.

Кейс: Сердечно-сосудистые заболевания

Аналитическая часть: Средний возраст, вес, рост пациентов заболеванием и без (MapReduce)

Источник: <https://www.kaggle.com/datasets/colewelkins/cardiovascular-disease>

Описание датасета:

Демографические переменные

ID

Уникальный идентификатор пациента. Используется для однозначной идентификации записей в датасете.

age

Возраст пациента в днях на момент обследования. Преобразуется в годы для анализа. Диапазон: 18-100 лет (6570-36500 дней).

age_years

Возраст пациента в годах (производная переменная). Рассчитывается как age / 365. Критически важный фактор риска сердечно-сосудистых заболеваний.

gender

Пол пациента. Кодировка: 1 - женский, 2 - мужской. Мужской пол является независимым фактором риска.

height

Рост пациента в сантиметрах. Используется вместе с весом для расчета индекса массы тела (ВМТ). Диапазон: 100-250 см.

weight

Вес пациента в килограммах. Вместе с ростом определяет статус питания пациента. Диапазон: 30-200 кг.

Клинические показатели

ap_hi

Систолическое артериальное давление (верхнее значение) в мм рт.ст.

Показывает давление в артериях в момент сокращения сердца. Норма: 90-120 мм рт.ст.

ap_lo

Диастолическое артериальное давление (нижнее значение) в мм рт.ст.

Показывает давление в артериях в момент расслабления сердца. Норма: 60-80 мм рт.ст.

cholesterol

Уровень холестерина в крови. Категориальная переменная:

- 1: Нормальный уровень (< 200 мг/дл)
- 2: Выше нормального (200-239 мг/дл)
- 3: Значительно выше нормального (≥ 240 мг/дл)

gluc

Уровень глюкозы в крови. Категориальная переменная:

- 1: Нормальный уровень (< 100 мг/дл)
- 2: Выше нормального (100-125 мг/дл)
- 3: Значительно выше нормального (≥ 126 мг/дл)

Факторы образа жизни

smoke

Статус курения. Бинарная переменная:

- 0: Не курит
- 1: Курит (текущий курильщик)

alco

Употребление алкоголя. Бинарная переменная:

- 0: Не употребляет алкоголь
- 1: Употребляет алкоголь

active

Уровень физической активности. Бинарная переменная:

- 0: Не активен (сидячий образ жизни)
- 1: Активен (регулярная физическая активность)

Производные и целевые переменные

bmi

Индекс массы тела (Body Mass Index). Рассчитывается как $\text{weight} / (\text{height}/100)^2$. Классификация:

- <18.5 : Недостаточный вес
- $18.5-24.9$: Нормальный вес
- $25-29.9$: Избыточный вес
- ≥ 30 : Ожирение

bp_category

Категория артериального давления на основе ap_hi и ap_lo:

- "Normal": Нормальное ($<120/<80$)

- "Elevated": Повышенное ($120\text{-}129/\text{<}80$)
- "Hypertension Stage 1": Гипертония 1 стадии ($130\text{-}139/80\text{-}89$)
- "Hypertension Stage 2": Гипертония 2 стадии ($\geq 140/\geq 90$)
- "Hypertensive Crisis": Гипертонический криз ($>180/>120$)

bp_category_encoded

Закодированная версия bp_category для машинного обучения:

- 0: Normal
- 1: Elevated
- 2: Hypertension Stage 1
- 3: Hypertension Stage 2
- 4: Hypertensive Crisis

cardio

Целевая переменная - наличие сердечно-сосудистого заболевания:

- 0: Отсутствие сердечно-сосудистого заболевания
- 1: Наличие сердечно-сосудистого заболевания

Дополнительные расчетные переменные

risk_factors

Суммарное количество факторов риска у пациента. Рассчитывается как сумма:

- Высокое давление ($\text{bp_category_encoded} \geq 2$)
- Высокий холестерин ($\text{cholesterol} \geq 2$)
- Высокая глюкоза ($\text{gluc} \geq 2$)
- Курение ($\text{smoke} = 1$)

- Ожирение ($bmi \geq 30$)

age_group

Возрастная группа пациента. Категории:

- 18-29 лет
- 30-39 лет
- 40-49 лет
- 50-59 лет
- 60-69 лет
- 70+ лет

bmi_category

Категория индекса массы тела:

- Недостаточный вес (<18.5)
- Нормальный вес (18.5-24.9)
- Избыточный вес (25-29.9)
- Ожирение I степени (30-34.9)
- Ожирение II+ степени (≥ 35)

Выполнение:

Запуск проекта

Шаг 1. Клонирование и подготовка

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

● hadoop@devopsvm:~$ cd /home/hadoop/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1
● hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ ls -la hadoop/
total 36
drwxrwxr-x 2 hadoop hadoop 4096 Oct 29 08:03 .
drwxrwxr-x 5 hadoop hadoop 4096 Oct 29 08:03 ..
-rw-rw-r-- 1 hadoop hadoop 1215 Oct 29 08:03 capacity-scheduler.xml
-rw-rw-r-- 1 hadoop hadoop 1509 Oct 29 08:03 core-site.xml
-rw-rw-r-- 1 hadoop hadoop 2820 Oct 29 08:03 hdfs-site.xml
-rw-rw-r-- 1 hadoop hadoop 1423 Oct 29 08:03 log4j.properties
-rw-rw-r-- 1 hadoop hadoop 2260 Oct 29 08:03 mapred-site.xml
-rw-rw-r-- 1 hadoop hadoop 9 Oct 29 08:03 workers
-rw-rw-r-- 1 hadoop hadoop 3040 Oct 29 08:03 yarn-site.xml
○ hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ █

● hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ ls -la scripts/
total 28
drwxrwxr-x 2 hadoop hadoop 4096 Oct 29 08:03 .
drwxrwxr-x 5 hadoop hadoop 4096 Oct 29 08:03 ..
-rw-rw-r-- 1 hadoop hadoop 4145 Oct 29 08:03 analyze_pandas.py
-rw-rw-r-- 1 hadoop hadoop 5579 Oct 29 08:03 analyze_spark.py
-rw-rw-r-- 1 hadoop hadoop 643 Oct 29 08:03 start_jupyter.sh
● hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ ls -la notebooks/
total 144
drwxrwxr-x 2 hadoop hadoop 4096 Oct 29 08:03 .
drwxrwxr-x 5 hadoop hadoop 4096 Oct 29 08:03 ..
-rw-rw-r-- 1 hadoop hadoop 137863 Oct 29 08:03 earthquake_analysis.ipynb
○ hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ █
```

Шаг 2. Запуск Docker контейнера

Запуск контейнера:

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

=> [hadoop] resolving provenance for metadata file
[+] Running 4/4
  ✓ hadoop                      Built
  ✓ Network "lw_5_1_default"      Created
  ✓ Volume "lw_5_1_hadoop_data"   Created
  ✓ Container hadoop-cluster     Created

hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ sudo docker compose up -d
[sudo] password for hadoop:
[+] Running 1/1
  ✓ Container hadoop-cluster    Started
```

Просмотр логов:

```
o hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ sudo docker compose logs -f hadoop
hadoop-cluster | Formatting NameNode...
hadoop-cluster | Starting SSH...
hadoop-cluster | * Starting OpenBSD Secure Shell server sshd [ OK ]
hadoop-cluster | Starting HDFS...
hadoop-cluster | Starting namenodes on [hadoop]
hadoop-cluster | hadoop: Warning: Permanently added 'hadoop,172.18.0.2' (ECDSA) to the list of known hosts.
hadoop-cluster | Starting datanodes
hadoop-cluster | localhost: Warning: Permanently added 'localhost' (ECDSA) to the list of known hosts.
hadoop-cluster | Starting secondary namenodes [hadoop]
hadoop-cluster | Starting YARN...
hadoop-cluster | Starting resourcemanager
hadoop-cluster | Starting nodemanagers
hadoop-cluster | Uploading data to HDFS...
hadoop-cluster | Data uploaded to HDFS successfully
hadoop-cluster | Hadoop started!
hadoop-cluster | 721 ResourceManager
hadoop-cluster | 819 NodeManager
hadoop-cluster | 198 NameNode
hadoop-cluster | 1255 Jps
hadoop-cluster | 476 SecondaryNameNode
hadoop-cluster | 302 DataNode
hadoop-cluster | Starting SSH...
hadoop-cluster | * Starting OpenBSD Secure Shell server sshd [ OK ]
hadoop-cluster | Starting HDFS...
hadoop-cluster | Starting namenodes on [hadoop]
hadoop-cluster | Starting datanodes
hadoop-cluster | Starting secondary namenodes [hadoop]
hadoop-cluster | Starting YARN...
hadoop-cluster | Starting resourcemanager
hadoop-cluster | Starting nodemanagers
hadoop-cluster | Uploading data to HDFS...
hadoop-cluster | put: `/data/database.csv': File exists
hadoop-cluster | Data uploaded to HDFS successfully
hadoop-cluster | Hadoop started!
hadoop-cluster | 400 SecondaryNameNode
hadoop-cluster | 243 DataNode
hadoop-cluster | 148 NameNode
hadoop-cluster | 1241 Jps
hadoop-cluster | 778 NodeManager
hadoop-cluster | 683 ResourceManager
```

Шаг 3. Подключение к контейнеру

```
o hadoop@devopsvm:~/Downloads/BigDataAnalytic-main/lw/2025/lw_5_1$ sudo docker compose exec hadoop bash
root@hadoop:/opt# hostname
hadoop
root@hadoop:/opt#
```

Шаг 4. Проверка компонентов Hadoop

```
root@hadoop:/opt# jps
400 SecondaryNameNode
243 DataNode
1284 Jps
148 NameNode
778 NodeManager
683 ResourceManager
root@hadoop:/opt#
```

Работа с HDFS

Шаг 1. Создание директорий

```
root@hadoop:/opt# hdfs dfs -mkdir -p /user/hadoop/input
root@hadoop:/opt# hdfs dfs -mkdir -p /user/hadoop/output
root@hadoop:/opt# hdfs dfs -ls /user/hadoop/
Found 2 items
drwxr-xr-x  - root supergroup          0 2025-11-01 21:37 /user/hadoop/input
drwxr-xr-x  - root supergroup          0 2025-11-01 21:37 /user/hadoop/output
```

Шаг 2. Загрузка данных

```
root@hadoop:/opt# hdfs dfs -put /opt/data/database.csv /user/hadoop/input/database.csv
root@hadoop:/opt# hdfs dfs -ls -h /user/hadoop/input/
Found 1 items
-rw-r--r-- 1 root supergroup 263.7 M 2025-11-02 19:32 /user/hadoop/input/database.csv
root@hadoop:/opt# hdfs dfs -du -h /user/hadoop/input/
263.7 M 263.7 M /user/hadoop/input/database.csv
root@hadoop:/opt#
```

Шаг 3. Просмотр данных в HDFS

```
root@hadoop:/opt# hdfs dfs -cat /user/hadoop/input/database.csv | head -20
id,age,gender,height,weight,ap_hi,ap_lo,cholesterol,gluc,smoke,alco,active,age_years,bmi,bp_category,bp_category_encoded,cardio
0,30224,2,185,87224718882146,85,77148066198586,124,52564039774707,77,23675158046012,2,2,0,0,0,82,24,826403415583023,Elevated,1,0
1,22365,1,166,0,23821270527,71,808496198129,127,62572041939552,75,7433777993652,2,1,0,0,61,26,051637161060356,Elevated,1,1
2,7430,1,159,0,06081725239952,63,07989502940309,114,0413885964915,72,33155835634754,1,1,0,0,0,20,24,932426240566414,Normal,0,0
3,11960,2,172,692435994157,97,99928205188083,112,77031783161712,65,67366983389083,1,3,0,0,1,32,32,860658543033416,Normal,0,1
4,36372,1,153,36405963453166,61,281943043556154,129,35981078049227,85,36393718699448,2,1,0,0,1,99,26,054655473184706,Hypertension Stage 1,2,0
5,28145,1,164,50686723857862,60,88146134623014,132,34323100624948,88,11040501824732,1,1,0,0,1,77,22,496606104367398,Hypertension Stage 1,2,0
6,18534,2,172,73275703240878,90,14450476611013,115,1600167405814,84,32277002637123,2,1,0,0,1,50,30,212721488443634,Hypertension Stage 1,2,0
7,17854,2,178,12014719892684,64,26743892120567,105,12403115045794,75,15883917572481,1,1,0,1,1,48,20,256523060158607,Normal,0,1
8,28688,2,177,8012263549538,78,50092740916494,118,62254237189309,92,00448827301796,2,3,0,0,1,78,24,831633133314767,Hypertension Stage 2,3,1
9,12835,2,179,12534379024203,86,10919489650644,128,30575509636975,75,24439521002991,1,2,0,0,0,35,26,83709198941842,Elevated,1,1
10,23420,1,167,87941766252916,57,56456036121882,129,9477131859702,90,42125209968196,1,1,0,0,0,64,20,424916230991325,Hypertension Stage 2,3,1
11,36480,1,171,34073222161203,66,26327678942125,135,64337269132469,78,2083934838593,1,2,1,0,1,99,22,57104524651042,Hypertension Stage 1,2,1
12,10996,1,157,74684727518783,80,92092803969183,121,06861579792951,76,51126807553023,1,1,0,0,0,30,32,5191719488659,Normal,1,1
13,28532,1,157,01896109453398,84,54065724359947,125,74132903180507,86,55628477011048,2,1,0,0,1,78,34,289521186107386,Hypertension Stage 1,2,1
14,20993,2,160,95432514199592,63,551684894112376,129,76586864319677,67,64565930344534,3,2,0,0,0,57,24,53136792779673,Elevated,1,0
15,34590,1,173,11399632968986,69,72880604012447,131,89297250380358,77,88214122937103,2,1,0,0,0,94,23,267400455808982,Hypertension Stage 1,2,0
16,17933,1,151,44196897265195,53,927221509902606,114,08304462003952,85,06164732361464,1,1,0,0,1,49,23,45476154176759,Hypertension Stage 1,2,0
17,34065,1,167,4207270407917,71,47032350729756,128,6019344531347,83,88117916008576,1,2,0,0,0,93,25,498069514820234,Hypertension Stage 1,2,0
18,22593,1,159,33812363116337,61,51128621939509,119,24377395290806,80,5903998598918,1,3,0,0,1,61,24,22787894374214,Hypertension Stage 1,2,0
```

```
root@hadoop:/opt# hdfs dfsadmin -report
Configured Capacity: 36669259776 (34.15 GB)
Present Capacity: 10752360448 (10.01 GB)
DFS Remaining: 10473652224 (9.75 GB)
DFS Used: 278708224 (265.80 MB)
DFS Used%: 2.5%
Replicated Blocks:
    Under replicated blocks: 0
    Blocks with corrupt replicas: 0
    Missing blocks: 0
    Missing blocks (with replication factor 1): 0
    Low redundancy blocks with highest priority to recover: 0
    Pending deletion blocks: 0
Erasure Coded Block Groups:
    Low redundancy block groups: 0
    Block groups with corrupt internal blocks: 0
    Missing block groups: 0
    Low redundancy blocks with highest priority to recover: 0
    Pending deletion blocks: 0
```

Шаг 4. Веб-интерфейсы

HDFS NameNode UI: <http://localhost:9870>

Browse Directory

<input type="text" value="/user/hadoop/input/"/>		<input type="button" value="Go!"/>				
Show <input type="button" value="25"/> entries	Search: <input type="text"/>					
<input type="checkbox"/>	Permission	Owner	Group	Size	Last Modified	Replication
<input type="checkbox"/>	-rw-r--r--	root	supergroup	263.68 MB	Nov 02 22:32	1
Showing 1 to 1 of 1 entries						
Previous		1	Next			

Hadoop, 2022.

YARN ResourceManager UI: <http://localhost:8088>

The screenshot shows the YARN ResourceManager UI with the title "All Applications". On the left, there's a sidebar with "Cluster Metrics" and "Scheduler Metrics" sections, and a "Tools" section containing a "Scheduler" link. The main area has tabs for "Active Nodes", "Decommissioning Nodes", "Decommissioned Nodes", "Lost Nodes", and "Unhealthy Node". Below these tabs is a table with columns: ID, User, Name, Application Type, Application Tags, Queue, Application Priority, StartTime, LaunchTime, FinishTime, State, FinalStatus, Running Containers, Allocated CPU Vcores, Allocated Memory MB, and Allocated GPUs. A message "No data available in table" is displayed at the bottom of the table. At the very bottom, it says "Showing 0 to 0 of 0 entries".

Directory: /logs/

Name	Last Modified	Size
hadoop-root-datanode-hadoop.out	Nov 2, 2025, 8:53:11 PM	2,759 bytes
hadoop-root-datanode-hadoop.out.1	Nov 2, 2025, 8:36:30 PM	3,713 bytes
hadoop-root-datanode-hadoop.out.2	Nov 1, 2025, 9:55:49 PM	2,757 bytes
hadoop-root-namenode-hadoop.out	Nov 2, 2025, 9:25:31 PM	10,042 bytes
hadoop-root-namenode-hadoop.out.1	Nov 2, 2025, 8:34:26 PM	10,178 bytes
hadoop-root-namenode-hadoop.out.2	Nov 1, 2025, 9:55:50 PM	3,779 bytes
hadoop-root-nodemanager-hadoop.out	Nov 2, 2025, 8:54:20 PM	4,708 bytes
hadoop-root-nodemanager-hadoop.out.1	Nov 2, 2025, 7:26:01 PM	4,708 bytes
hadoop-root-nodemanager-hadoop.out.2	Nov 1, 2025, 9:56:22 PM	4,707 bytes
hadoop-root-resourcemanager-hadoop.out	Nov 2, 2025, 8:54:20 PM	4,734 bytes
hadoop-root-resourcemanager-hadoop.out.1	Nov 2, 2025, 7:25:57 PM	4,736 bytes
hadoop-root-resourcemanager-hadoop.out.2	Nov 1, 2025, 9:56:21 PM	4,731 bytes
hadoop-root-secondarynamenode-hadoop.out	Nov 2, 2025, 8:53:13 PM	2,504 bytes
hadoop-root-secondarynamenode-hadoop.out.1	Nov 2, 2025, 7:26:15 PM	2,592 bytes
hadoop-root-secondarynamenode-hadoop.out.2	Nov 1, 2025, 9:56:57 PM	2,592 bytes
userlogs/	Nov 1, 2025, 9:56:10 PM	4,096 bytes

Работа с Bash – подсчет количества строк:

```
root@hadoop:/opt# hdfs dfs -cat /user/hadoop/input/database.csv | wc -l
2000001
root@hadoop:/opt#
```

Show 20 entries															Search:		
Node Labels	Rack	Node State	Node Address	Node HTTP Address	Last health-update	Health-report	Containers	Allocation Tags	Mem Used	Mem Avail	Phys Mem Used %	VCores Used	VCores Avail	Phys VCores Used %	Vers		
/ default-rack	RUNNING	hadoop:36077	hadoop:8042	Wed Nov 12 07:32:28 +0000 2025	0	0 B	2 GB	82	0	8	66	3.3.4					
Showing 1 to 1 of 1 entries																	
First	Previous	1	Next	Last													

Анализ данных

Загрузка данных:

Загрузка данных из HDFS...

Выполнение команды: hdfs dfs -get /user/hadoop/input/database.csv /opt/database.csv

Ошибка при загрузке из HDFS: get: '/opt/database.csv': File exists

Попытка найти файл локально...

Размер датасета: (2000000, 17)

Данные успешно загружены из /opt/data/database.csv

```
    id  age  gender    height    weight    ap_hi    ap_lo \
0   0  30224      2  185.872247  85.771481  124.525640  77.236752
1   1  22365      1  166.023821  71.808496  127.625720  75.743378
2   2  7430       1  159.060817  63.079895  114.041389  72.331558
3   3  11960      2  172.692436  97.999282  112.770318  65.673670
4   4  36372      1  153.364060  61.281943  129.359811  85.363937
```

```
 cholesterol  gluc  smoke  alco  active  age_years    bmi \
0            2     2     0     0     0        82  24.826403
1            2     1     1     0     0        61  26.051637
2            1     1     0     0     0        20  24.932426
3            1     3     0     0     1        32  32.860659
4            2     1     0     0     1        99  26.054655
```

```
    bp_category  bp_category_encoded  cardio
0          Elevated                  1      0
1          Elevated                  1      1
2          Normal                   0      0
3          Normal                   0      1
4 Hypertension Stage 1                 2      0
```

```
Информация о данных:  
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 2000000 entries, 0 to 1999999  
Data columns (total 17 columns):  
 #   Column           Dtype     
---  ----  
 0   id               int64  
 1   age              int64  
 2   gender            int64  
 3   height             float64  
 4   weight             float64  
 5   ap_hi              float64  
 6   ap_lo              float64  
 7   cholesterol        int64  
 8   gluc              int64  
 9   smoke              int64  
 10  alco              int64  
 11  active             int64  
 12  age_years          int64  
 13  bmi                float64  
 14  bp_category        object  
 15  bp_category_encoded int64  
 16  cardio             int64  
dtypes: float64(5), int64(11), object(1)  
memory usage: 259.4+ MB  
None
```

Очистка данных:

```
НАЧАЛО ОЧИСТКИ ДАННЫХ  
=====  
Исходный размер данных: (2000000, 17)  
  
1. ПРОВЕРКА ДУБЛИКАТОВ:  
Найдено дубликатов: 0  
  
2. ПРОВЕРКА ПРОПУЩЕННЫХ ЗНАЧЕНИЙ:  
Пропущенных значений не найдено ✓  
  
3. ОЧИСТКА ЧИСЛОВЫХ ДАННЫХ:  
Числовые колонки: ['id', 'age', 'gender', 'height', 'weight', 'ap_hi', 'ap_lo', 'cholesterol', 'gluc', 'smoke', 'alco', 'active', 'age_years', 'bmi', 'bp_category_encoded', 'cardio']  
  
4. СПЕЦИФИЧНАЯ ОЧИСТКА МЕДИЦИНСКИХ ДАННЫХ:  
Возраст ограничен 18-100 годами  
Возраст в годах ограничен 18-100 годами  
Рост (height) ограничен 100-250 см  
Вес (weight) ограничен 30-200 кг  
Систолическое давление ограничено 60-250 мм рт.ст.  
Диастолическое давление ограничено 40-150 мм рт.ст.  
  
5. ПРОВЕРКА КАТЕГОРИАЛЬНЫХ ПЕРЕМЕННЫХ:  
bp_category: 4 уникальных значений  
  
6. ПРОВЕРКА БИНАРНЫХ ПЕРЕМЕННЫХ:  
Потенциальные бинарные переменные: ['smoke', 'alco', 'active', 'cardio']  
smoke преобразована в бинарную (0/1)  
alco преобразована в бинарную (0/1)  
active преобразована в бинарную (0/1)  
cardio преобразована в бинарную (0/1)  
  
7. ФИНАЛЬНАЯ ПРОВЕРКА:  
Удалено строк: 0  
Удалено колонок: 0  
Финальный размер: (2000000, 17)  
Сохранено данных: 100.0%  
  
Распределение целевой переменной 'cardio':  
 0: 62.7%  
 1: 37.3%  
  
=====  
ОЧИСТКА ДАННЫХ ЗАВЕРШЕНА  
=====
```

Проверка качества данных после очистки

=====

ОТЧЕТ О КАЧЕСТВЕ ДАННЫХ

=====

Общее количество записей: 2,000,000

Количество признаков: 17

ТИПЫ ДАННЫХ:

int64: 11 колонок
float64: 5 колонок
object: 1 колонок

СТАТИСТИКА ПО ЧИСЛОВЫМ ПРИЗНАКАМ (16):

	count	mean	std	min	50%	\
id	2000000.0	999999.50	577350.41	0.00	999999.50	
age	2000000.0	21548.90	8640.11	6570.00	21552.00	
gender	2000000.0	1.48	0.50	1.00	1.00	
height	2000000.0	168.24	9.18	141.01	167.65	
weight	2000000.0	72.19	13.25	35.19	71.48	
ap_hi	2000000.0	122.51	10.76	92.36	122.51	
ap_lo	2000000.0	77.51	7.38	57.14	77.51	
cholesterol	2000000.0	1.55	0.67	1.00	1.00	
gluc	2000000.0	1.38	0.62	1.00	1.00	
smoke	2000000.0	0.00	0.00	0.00	0.00	
alco	2000000.0	0.00	0.00	0.00	0.00	
active	2000000.0	0.65	0.48	0.00	1.00	
age_years	2000000.0	58.54	23.67	18.00	59.00	
bmi	2000000.0	25.52	4.37	13.63	25.37	
bp_category_encoded	2000000.0	1.20	0.95	0.00	1.00	
cardio	2000000.0	0.37	0.48	0.00	0.00	

	max	missing_percent
id	1999999.00	0.0
age	36499.00	0.0
gender	2.00	0.0
height	195.29	0.0
weight	108.69	0.0
ap_hi	152.65	0.0
ap_lo	97.88	0.0
cholesterol	3.00	0.0
gluc	3.00	0.0
smoke	0.00	0.0
alco	0.00	0.0
active	1.00	0.0
age_years	99.00	0.0
bmi	37.26	0.0
bp_category_encoded	3.00	0.0
cardio	1.00	0.0

ПРОВЕРКА МЕДИЦИНСКОЙ ЛОГИКИ:

Найдено 1 записей где систолическое ≤ диастолическому

✓ Средняя разница расчетного и заданного BMI: 0.01

АНАЛИЗ РАСПРЕДЕЛЕНИЙ:

age_years: распределение близко к нормальному (skewness = -0.00)
height: распределение близко к нормальному (skewness = 0.19)
weight: распределение близко кциальному (skewness = 0.20)

АНАЛИЗ ЦЕЛЕВОЙ ПЕРЕМЕННОЙ:

Распределение: 62.7% без болезни, 37.3% с болезнью


Дисбаланс классов - может потребоваться балансировка

=====


ОТЧЕТ ЗАВЕРШЕН

Визуализация распределений после очистки


Визуализация распределений данных...



Boxplot ключевых переменных (после очистки)



MapReduce анализ на очищенных данных



ДЕТАЛЬНАЯ СТАТИСТИКА АНАЛИЗА

С сердечно-сосудистым заболеванием:

- Количество пациентов: 746,877
- Средний возраст: 67.2 ± 21.9 лет
- Средний вес: 74.4 ± 13.5 кг
- Средний рост: 168.8 см
- Средний BMI: 26.2

Без сердечно-сосудистого заболевания:


- Количество пациентов: 1,253,123
- Средний возраст: 53.3 ± 23.2 лет
- Средний вес: 70.9 ± 12.9 кг
- Средний рост: 167.9 см
- Средний BMI: 25.2


ВЫВОДЫ:

- Пациенты с заболеванием в среднем на 13.9 лет старше
- Пациенты с заболеванием в среднем на 3.5 кг тяжелее
- Разница в BMI составляет 1.0 единицы
- ВОЗРАСТ: Значительная разница - возраст важный фактор риска

Анализ завершен успешно!

Расширенный анализ факторов риска





Финальный отчет и выводы

ФИНАЛЬНЫЙ ОТЧЕТ АНАЛИЗА СЕРДЕЧНО-СОСУДИСТЫХ ЗАБОЛЕВАНИЙ

ОБЩАЯ СТАТИСТИКА:

- Всего пациентов: 2,000,000
- Процент с заболеванием: 37.3%

СРАВНИТЕЛЬНЫЙ АНАЛИЗ:

- Разница в возрасте: +13.9 лет
- Разница в весе: +3.5 кг
- Разница в BMI: +1.0

КЛЮЧЕВЫЕ ВЫВОДЫ:

- ✓ Возраст является значимым фактором риска

РЕКОМЕНДАЦИИ:

1. Регулярный мониторинг артериального давления
2. Контроль веса и BMI в нормальных пределах
3. Регулярная физическая активность
4. Здоровое питание с ограничением соли и жиров
5. Отказ от курения и умеренное потребление алкоголя

АНАЛИЗ ЗАВЕРШЕН

Итоговый анализ по заданию

ИТОГОВЫЙ АНАЛИЗ: СРЕДНИЙ ВОЗРАСТ, ВЕС, РОСТ


Проводим анализ...

РАСПРЕДЕЛЕНИЕ ПАЦИЕНТОВ:

- С заболеванием: 746,877 пациентов
- Без заболевания: 1,253,123 пациентов
- Всего: 2,000,000 пациентов

ТАБЛИЦА СРЕДНИХ ПОКАЗАТЕЛЕЙ:

Показатель	С заболеванием	Без заболевания	Разница
Возраст (лет)	67.2	53.3	+13.9
Вес (кг)	74.4	70.9	+3.5
Рост (см)	168.8	167.9	+0.9
BMI	26.2	25.2	+1.0



КЛЮЧЕВЫЕ ВЫВОДЫ:


- Пациенты с заболеванием в среднем на 13.9 лет СТАРШЕ
- Пациенты с заболеванием в среднем на 3.5 кг ТЯЖЕЛЕЕ
- Пациенты с заболеванием в среднем на 0.9 см ВЫШЕ
- У пациентов с заболеванием BMI на 1.0 ВЫШЕ

Наибольшая разница наблюдается в показателе: Возраст

ИТОГОВЫЙ АНАЛИЗ ЗАВЕРШЕН!

Результаты сохранены в: /opt/final_analysis_results.csv

Исправленные графики:



РЕЗУЛЬТАТЫ АНАЛИЗА

Средний вес:

- С заболеванием: 74.4 кг
- Без заболевания: 70.9 кг
- Разница: +3.5 кг

Средний рост:

- С заболеванием: 168.8 см
- Без заболевания: 167.9 см
- Разница: +0.9 см

Средний BMI:

- С заболеванием: 26.2
- Без заболевания: 25.2
- Разница: +1.0

Загрузка в HDFS

Пример на одном из графиков:



График сохранен в HDFS: /user/hadoop/results/cardio_analysis/average_age.png

Проверка файлов в HDFS:

Found 4 items

```
-rw-r--r-- 1 root supergroup      93052 2025-11-03 11:47 /user/hadoop/results/cardio_analysis/average_age.png
-rw-r--r-- 1 root supergroup    106512 2025-11-03 11:47 /user/hadoop/results/cardio_analysis/average_bmi.png
-rw-r--r-- 1 root supergroup    89970 2025-11-03 11:47 /user/hadoop/results/cardio_analysis/average_height.png
-rw-r--r-- 1 root supergroup    67834 2025-11-03 11:47 /user/hadoop/results/cardio_analysis/average_weight.png
```

Directory: /logs/

Name	Last Modified	Size
hadoop-root-datanode-hadoop.out	Nov 3, 2025, 11:38:36 AM	2,757 bytes
hadoop-root-datanode-hadoop.out.1	Nov 3, 2025, 9:18:24 AM	2,759 bytes
hadoop-root-datanode-hadoop.out.2	Nov 2, 2025, 8:53:11 PM	2,759 bytes
hadoop-root-datanode-hadoop.out.3	Nov 2, 2025, 8:36:30 PM	3,713 bytes
hadoop-root-datanode-hadoop.out.4	Nov 1, 2025, 9:55:49 PM	2,757 bytes
hadoop-root-namenode-hadoop.out	Nov 3, 2025, 11:38:37 AM	3,780 bytes
hadoop-root-namenode-hadoop.out.1	Nov 3, 2025, 10:10:31 AM	4,273 bytes



Browse Directory

The screenshot shows a table of file entries in the /user/hadoop/results/cardio_analysis directory. The columns include Name, Size, Last Modified, Replication, Block Size, and Name. The files listed are average_age.png, average_bmi.png, average_height.png, and average_weight.png, all of which are 128 MB in size and were modified on Nov 03 14:47.

Name	Size	Last Modified	Replication	Block Size	Name
average_age.png	90.87 KB	Nov 03 14:47	1	128 MB	average_age.png
average_bmi.png	104.02 KB	Nov 03 14:47	1	128 MB	average_bmi.png
average_height.png	87.86 KB	Nov 03 14:47	1	128 MB	average_height.png
average_weight.png	66.24 KB	Nov 03 14:47	1	128 MB	average_weight.png

Hadoop, 2022.

Сохранение таблиц

Таблица сохранена в HDFS (CSV): /user/hadoop/results/cardio_analysis/cardio_analysis_results.csv
Таблица сохранена в HDFS (JSON): /user/hadoop/results/cardio_analysis/cardio_analysis_results.json
Отчет сохранен в HDFS (TXT): /user/hadoop/results/cardio_analysis/cardio_analysis_report.txt

ТАБЛИЦА РЕЗУЛЬТАТОВ:

Показатель	Единица измерения	С_заболеванием	Без_заболевания	Разница	Абсолютная_разница
Возраст	лет	67.2	53.3	13.9	13.9
Вес	кг	74.4	70.9	3.5	3.5
Рост	см	168.8	167.9	0.9	0.9
Индекс массы тела		26.2	25.2	1.0	1.0

ФАЙЛЫ В HDFS:

Found 8 items

-rw-r--r--	1	root	supergroup	93052	2025-11-03 19:44	/user/hadoop/results/cardio_analysis/average_age.png
-rw-r--r--	1	root	supergroup	106512	2025-11-03 19:44	/user/hadoop/results/cardio_analysis/average_bmi.png
-rw-r--r--	1	root	supergroup	89970	2025-11-03 19:44	/user/hadoop/results/cardio_analysis/average_height.png
-rw-r--r--	1	root	supergroup	67834	2025-11-03 19:44	/user/hadoop/results/cardio_analysis/average_weight.png
-rw-r--r--	1	root	supergroup	1490	2025-11-03 19:53	/user/hadoop/results/cardio_analysis/cardio_analysis_report.txt
-rw-r--r--	1	root	supergroup	538	2025-11-03 19:53	/user/hadoop/results/cardio_analysis/cardio_analysis_results.csv
-rw-r--r--	1	root	supergroup	886	2025-11-03 19:53	/user/hadoop/results/cardio_analysis/cardio_analysis_results.json
-rw-r--r--	1	root	supergroup	188971	2025-11-03 19:36	/user/hadoop/results/cardio_analysis/summary_comparison.png

Сохранение в формате Excel:

Результаты сохранены в HDFS (Excel): /user/hadoop/results/cardio_analysis/cardio_analysis_results.xlsx

Итого в HDFS:

	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
□	-rw-r--r--	root	supergroup	90.87 KB	Nov 03 22:44	1	128 MB	average_age.png	trash
□	-rw-r--r--	root	supergroup	104.02 KB	Nov 03 22:44	1	128 MB	average_bmi.png	trash
□	-rw-r--r--	root	supergroup	87.86 KB	Nov 03 22:44	1	128 MB	average_height.png	trash
□	-rw-r--r--	root	supergroup	66.24 KB	Nov 03 22:44	1	128 MB	average_weight.png	trash
□	-rw-r--r--	root	supergroup	1.46 KB	Nov 03 22:53	1	128 MB	cardio_analysis_report.txt	trash
□	-rw-r--r--	root	supergroup	538 B	Nov 03 22:53	1	128 MB	cardio_analysis_results.csv	trash
□	-rw-r--r--	root	supergroup	886 B	Nov 03 22:53	1	128 MB	cardio_analysis_results.json	trash
□	-rw-r--r--	root	supergroup	7.16 KB	Nov 03 23:01	1	128 MB	cardio_analysis_results.xlsx	trash
□	-rw-r--r--	root	supergroup	184.54 KB	Nov 03 22:36	1	128 MB	summary_comparison.png	trash

Выводы:

В ходе выполнения лабораторной работы была успешно освоена комплексная работа с распределенной файловой системой HDFS через Jupyter Notebook и проведен полный анализ больших медицинских данных.

Были получены практические навыки подключения к Hadoop Distributed File System из среды Jupyter, что позволило организовать эффективное взаимодействие между локальной аналитической средой и распределенным хранилищем данных. Освоены операции загрузки и выгрузки данных, создание директорий и управление файловой структурой в HDFS.

Проведена масштабная обработка медицинского датасета объемом более 250 МБ, содержащего свыше 2 миллионов записей о пациентах. Реализован комплексный процесс очистки данных, включающий удаление дубликатов, обработку пропущенных значений, фильтрацию статистических выбросов и проверку медицинской логики на корректность показателей артериального давления, возраста и индекса массы тела.

Важным достижением стала успешная реализация парадигмы MapReduce для распределенного анализа данных. Разработаны специализированные mapper и reducer функции, позволившие провести сравнительный анализ средних показателей между группами пациентов с сердечно-сосудистыми заболеваниями и без них. Также создана альтернативная система локального анализа для случаев недоступности Hadoop-кластера.

Результаты исследования были визуализированы в виде серии информативных графиков, отображающих распределение ключевых показателей: среднего возраста, веса, роста и индекса массы тела пациентов. Все полученные результаты сохранены в HDFS в multiple форматах, включая

графические файлы (PNG), структурированные таблицы (CSV, JSON, Excel) и подробные текстовые отчеты.

Аналитическая часть работы выявила статистически значимые различия между группами пациентов. Установлено, что возраст является важным фактором риска развития сердечно-сосудистых заболеваний, а показатели веса и индекса массы тела у пациентов с заболеваниями существенно превышают соответствующие показатели в контрольной группе.

Разработанный аналитический пайплайн демонстрирует практическую применимость для решения реальных задач в области медицинской аналитики, может быть использован для мониторинга факторов риска, создания систем поддержки врачебных решений и образовательных целей в области обработки больших данных.

Лабораторная работа успешно завершена, все поставленные задачи выполнены в полном объеме. Полученные навыки работы с HDFS, MapReduce и анализом больших данных представляют значительную ценность для дальнейшей профессиональной деятельности в области Data Science и распределенных вычислений.